SGH Warszawa · Instytut Ekonometrii

Ekonometria Bayesowska

Notatki do egzaminu — dr Andrzej Toroj

Wzory w LaTeX · Tagi do Ctrl+F · Lokalizacje w wykladach · Pelne rozwiazania

Spis tresci

W1	Twierdzenie Bayesa · rozklad beta · Euro 2016 · Mundial 2018
W2	Model ze stala (N+N) · parametry a posteriori · symulacja R
W3	Regresja z jedna zmienna · rozklad normalny-gamma · prawo Okuna
W4	Regresja wieloraka · HPDI · nieinformacyjne a priori · popyt na benzyne
W5	Czynnik Bayesa · iloraz szans a posteriori · restrykcje nierownosci
W6	Rozklad predykcyjny · prognozowanie · ceny domow (Koop)
W7	Importance Sampling · metody numeryczne
W8	Probnik Gibbsa · gestosc brzegowa modelu · bridge sampling
W9	Algorytm Metropolisa-Hastingsa · diagnostyka MCMC · CODA
W10	Monte Carlo Hamiltona (HMC) · NUTS · Stan
W11	Predykcja przy nieznanych regresorach · imputacja
W12	Bayesowskie usrednianie modeli (BMA)
EG	**Egzamin 22.12.2016** — tresci + wykresy + rozwiazania + dlaczego
P1	Egzamin probny 1 — parametry a posteriori, obliczenia, BF, MCMC
P2	Egzamin probny 2 — pytania koncepcyjne, Gibbs, BF vs P(beta>0|y)
P3	Egzamin probny 3 — obliczeniowy, HPDI, MH vs HMC, predykcja

Wyklad 1

Twierdzenie Bayesa · rozklady a priori i a posteriori

Przyklad: UEFA Euro 2016 · Filozofia bayesowska · Rozklad beta

twierdzenie Bayesa | a priori | a posteriori | rozklad beta | gestosc brzegowa | Euro 2016

Twierdzenie Bayesa — wzor kluczowy

$$p(\theta \mid y) = \frac{p(y \mid \theta) \cdot p(\theta)}{p(y)} \propto p(y \mid \theta) \cdot p(\theta)$$

$$p(y) = \int_{\Theta} p(y \mid \theta) \cdot p(\theta)\, d\theta \quad \text{(gestosc brzegowa modelu)}$$

Symbol	Nazwa	Interpretacja
$p(\theta)$	*a priori*	Wiedza o parametrze PRZED danymi
$p(y \mid \theta)$	Wiarygodnosc	Jak prawdopodobne sa dane przy danym θ
$p(\theta \mid y)$	*a posteriori*	Wiedza o parametrze PO danych
$p(y)$	Gestosc brzegowa	Stala normalizacyjna; kluczowa dla BF

Rozklad beta — a priori sprzezone dla proporcji

rozklad beta | sprzezone a priori | alpha beta | srednia wazona | k/n

$$r \sim \text{Beta}(\alpha, \beta), \quad E(r) = \frac{\alpha}{\alpha + \beta}, \quad D^2(r) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

Po k porazkach z n meczow (rozklad sprzezony z dwumianowym):

[ERR: $\bar\alpha = \alpha + k,\quad \bar\bet]

E(R|DANE) = SREDNIA WAZONA

Im wieksze $\alpha + \beta$ (silniejsze a priori), tym wieksza waga a priori wzgledem k/n.

Cwiczenie W1 — Mundial 2018

Mundial 2018 | rozklad beta | a posteriori | E(r|dane)

Polska — **8. miejsce w FIFA sposrod 32 zespolow**. Przegrywa **2 pierwsze mecze** (k=2, n=2). Oblicz E(r|dane) — prob. porazki w 3. meczu.

✓ **Rozwiazanie**

$$E(r)_{\text{prior}} = \frac{7}{31} \approx 0.226 \quad \text{(7 z 31 rywali wyzej w FIFA)}$$

Przy D(r)=0.15 szacujemy $a = 1.95, b = 6.68$. Po k=2: $E(r|dane) = (3.95/10.63) \approx 0.372$

Klasycznie k/n=1. Bayesowskie a priori hamuje wynik — nie ufamy 2 meczom w pelni.

Wyklad 2

Bayesowska analiza modelu ze stala (N+N)

Model yi=c+ei · Podstawy R i Stan

model ze stala | N+N | parametry a posteriori | sigma znane | Stan RStan

Parametry a posteriori — model N+N

$$\bar{\mu}_c = \frac{\sigma_c^2 \cdot n\bar{y} + \sigma^2 \cdot \mu_c}{n\sigma_c^2 + \sigma^2} = \bar{y} \cdot \frac{n\sigma_c^2}{n\sigma_c^2 + \sigma^2} + \mu_c \cdot \frac{\sigma^2}{n\sigma_c^2 + \sigma^2}$$

$$\bar{\sigma}_c^2 = \left(\frac{1}{\sigma_c^2} + \frac{n}{\sigma^2}\right)^{-1}$$

INTERPRETACJA

$\bar{\mu}_c$ = srednia wazona $\bar{y}$ i μ_c. Wzrost σ_c^2 (slabsze a priori) → wieksza waga danych. Wzrost n → $\bar{\sigma}_c^2$ maleje → wieksza pewnosc.

Zadanie W2 — symulacja a posteriori w R

symulacja R | gestosc a posteriori | mu_c_post | s2_c_post

Przy $sigma^2 = 1$, $mu_c = 0$, $sigma_c^2 = 0.3$, n=20, c_true=0.5 — wygeneruj dane i narysuj gestosci a priori i a posteriori.

✓ **Kod R**

```
c_true <- 0.5; sigma2 <- 1; mu_c <- 0; s2_c <- 0.3; n <- 20 set.seed(1); y <-
rnorm(n, c_true, sqrt(sigma2)) s2_c_post <- 1/(1/s2_c + n/sigma2) mu_c_post <-
s2_c_post*(mu_c/s2_c + n*mean(y)/sigma2) # Wynik: E(c|y)~0.46, Var(c|y)~0.047 --
precyzja wzrosla wielokrotnie
```

Wyklad 3

Regresja z jedna zmienna — rozklad normalny-gamma

N-G · parametry a posteriori · rozklad t-Studenta · prawo Okuna

normalny-gamma | N-G | parametry a posteriori | rozklad t | prawo Okuna | elicytacja | S_X | v_bar | u_bar

Model i a priori N-G

$$y_i = \beta x_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2), \quad h = 1/\sigma^2$$

$$(\beta, h) \sim NG(\bar{\beta}_0, u, s^{-2}, v) \Leftrightarrow \beta|h \sim N(\bar{\beta}_0, h^{-1}u),\ h \sim \Gamma(v/2, vs^2/2)$$

Parametry a posteriori

$$\bar{\beta} = \frac{\hat{\beta} \cdot S_X + \bar{\beta}_0 \cdot u^{-1}}{S_X + u^{-1}}, \qquad S_X = \sum x_i^2 \qquad \text{(srednia wazona OLS i a priori)}$$

$$\bar{u} = (u^{-1} + S_X)^{-1}, \qquad \bar{v} = v + N$$

$$\bar{v}\bar{s}^2 = vs^2 + \hat{v}\hat{s}^2 + \frac{(\hat{\beta} - \bar{\beta}_0)^2}{u + S_X^{-1}}$$

$$\beta \mid y \sim t(\bar{\beta},\ \bar{s}^2\bar{u},\ \bar{v}), \qquad \mathrm{Var}(\beta \mid y) = \frac{\bar{v} \cdot \bar{s}^2 \cdot \bar{u}}{\bar{v} - 2}$$

Parametr	Rola	Intuicja
$\bar{\beta}_0$	E a priori beta	Nasze "zgadniecie" (np. z literatury)
u	Skala wariancji a priori beta	~1/SumX^2 z poprzedniej proby
s^2	E wariancji reszt	Im mniejsze → silniejszy a priori na h
v	Waga a priori	~liczba poprzednich obserwacji

Przyklad W3 — Prawo Okuna (elicytacja a priori)

prawo Okuna | elicytacja | parametry u s^2 v | SD(beta)_prior

Dla USA: $betain(-0.5;\ -0.3)$. Uzasadnij: $bar_beta_0 = -0.4, s^2 = 0.1, u = 0.025, v = 100$.

✓ **Rozwiazanie**

$$\text{SD}(\beta)_{\text{prior}} = \sqrt{s^2 \cdot u} = \sqrt{0.1 \cdot 0.025} = 0.05$$

Przedzial $bar_beta_0pm2 * SD = -0.4pm0.1 = (-0.5; -0.3)$ = zakres z USA. v=100 ~ 25 lat danych kwartalnych USA.

Wyklad 4

Regresja wieloraka · HPDI · nieinformacyjne a priori

Postac macierzowa · popyt na benzyne · przedzialy najwyzszej gestosci

regresja wieloraka | HPDI | nieinformacyjne a priori | macierz U | XTX | qt.scaled | metRology

Parametry a posteriori — postac macierzowa

$$\bar{\beta} = (U^{-1} + X^T X)^{-1}(U^{-1}\bar{\beta}_0 + X^T y), \qquad \bar{U} = (U^{-1} + X^T X)^{-1}, \qquad \bar{v} = v + N$$

$$\beta_i \mid y \sim t(\bar{\beta}_i,\ \bar{s}^2 \cdot \bar{U}_{ii},\ \bar{v})$$

HPDI — Highest Posterior Density Interval

DEFINICJA I OBLICZENIE

Najkrotszy przedzial C taki, ze $P(\beta \in C \mid y) = 1 - \alpha$. Dla symetrycznego rozkładu t: HPDI = przedzial rownoogonowy.

```
library(metRology) qt.scaled(c(0.025, 0.975), df=v_bar, mean=beta_bar,
sd=sqrt(s2_bar * U_bar_ii))
```

Nieinformacyjne a priori → wyniki = OLS

u^{-1}->0 | limit OLS | beta_bar -> beta_OLS

$$\bar{\beta} \to \hat{\beta}_{\text{OLS}}, \quad \bar{U} \to (X^T X)^{-1}, \quad \bar{v} = N, \quad \bar{v}\bar{s}^2 = \hat{v}\hat{s}^2 \quad \text{gdy } u^{-1} \to 0$$

Zadanie W4 — popyt na benzyne (elicytacja)

popyt na benzyne | macierz U | elastycznosc

Model: log Q = b0 + b1*log P_gas + b2*log P_car + b3*log I + e. A priori: $beta_1 in (-1, 0)$, $beta_3 in (0, 1)$, $beta_2 < 0$.

✓ Parametry a priori

```
Beta.prior <- c(-22.5, -0.5, -0.5, 0.5) # stala, log_P_gas, log_P_car, log_I
sm2.prior <- 4 # s^{-2}=4 v.prior <- 100 U.prior <- 0.4*diag(4) U.prior[1,1] <-
200 # stala: brak wiedzy
```

Wyklad 5

Czynnik Bayesa · iloraz szans a posteriori

Porownanie modeli · skala Jeffreysa · restrykcje nierownosci

czynnik Bayesa | BF | iloraz szans | PO | skala Jeffreysa | P(M|y) | restrykcje nierownosci | pmvt

BF i iloraz szans a posteriori

[ERR: \mathrm{{PO}}(M_1,M_2) = \underbrace{{\]

BF(M1,M2)	Jeffreys (1961)	Kass-Raftery (1995)
<1	Negative — za M2	Za M2
1–3.16	Barely worth mentioning	Not worth mentioning
3.16–10	Substantial	Positive
10–31.6	Strong	Strong
>100	Decisive	Very strong

Restrykcje nierownosci

$$R\beta \mid y \sim t(R\bar{\beta},\ \bar{s}^2 R\bar{U}R^T,\ \bar{v})$$

$$\mathrm{PO}(R\beta \geq r,\ R\beta < r) = \frac{P(R\beta \geq r \mid y)}{1 - P(R\beta \geq r \mid y)}$$

Zadanie W5 — restrykcje nierownosci (elastycznosci)

pmvt | mvtnorm | PO nierownosci

Wyznacz PO gdy: (1) $beta_1 < 0$, (2) $beta_1 < 0 i beta_2 < 0$, (3) $beta_1 < 0 i beta_2 < 0 i beta_3 > 0$.

✓ **Kod R**

```
library(mvtnorm) R1 <- matrix(c(0,1,0,0), nrow=1) prob1 <- pmvt(upper=0,
mean=R1%*%beta.post, sigma=s2.post*R1%*%U.post%*%t(R1), df=v.post) PO1 <-
as.numeric(prob1/(1-prob1)) # Dla 3 restrykcji: zmien znaki dla nierownosci < 0
R3 <- matrix(c(0,-1,0,0, 0,0,-1,0, 0,0,0,1), nrow=3, byrow=TRUE) prob3 <-
pmvt(upper=c(0,0,0), mean=R3%*%beta.post, sigma=s2.post*R3%*%U.post%*%t(R3),
df=v.post)
```

Wyklad 6

Bayesowskie podejscie do predykcji

Rozklad predykcyjny · prognoza przedziałowa · ceny domow (Koop)

rozklad predykcyjny | predykcja bayesowska | prognoza przedziałowa | ceny domow | Koop | niepewnosc parametrow

Rozklad predykcyjny

$$p(y_\tau \mid y) = \iint p(y_\tau \mid \beta, h, x_\tau) \cdot p(\beta, h \mid y)\, d\beta\, dh$$

Wynik analityczny dla modelu N-G:

$$y_\tau \mid y \sim t\left(x_\tau \bar{\beta},\ \bar{s}^2\left(1 + x_\tau \bar{U} x_\tau^T\right),\ \bar{\nu}\right)$$

Czlon $x_\tau \bar{U} x_\tau^T$ = niepewnosc co do beta. Im dalej od zakresu proby → szerszy przedzial.

Klasyczne	Bayesowskie
Prognoza punktowa $\hat{y} = x_\tau \hat{\beta}$	Caly rozklad $p(y_\tau \mid y)$
Parametry traktowane jako znane	Uwzglednia niepewnosc beta i h
Rozklad N (asymptotycznie)	Rozklad t z v_bar st. sw. (grubsze ogony)

Zadanie W6 — ceny domow (Koop, rozdz. 3.9)

ceny domow | Koop | HPDI predykcji

Prognoza ceny: 5000 stop, 2 sypialnie, 2 lazienki, 1 kondygnacja. A priori Koopa: $bar_beta_0 = [0, 10, 5000, 10000, 10000]^T$, v=5, s^-2=4e-8.

✓ **Kod R**

```
x_tau <- c(1, 5000, 2, 2, 1) # stala, pow, sypialnie, lazienki, kondygnacje
y_hat <- x_tau %*% beta1 pred_var <- s2_post * (1 + x_tau %*% U1 %*% x_tau) HPDI
<- qt.scaled(c(0.025, 0.975), df=v1, mean=y_hat, sd=sqrt(pred_var))
```

Wyklady 7–12

Metody numeryczne · MCMC · HMC · BMA

IS · Gibbs · MH · Stan · predykcja numeryczna · BMA

W7 — Importance Sampling (IS)

Importance Sampling | IS | funkcja waznosci | ciezkie ogony q(theta)

$$w^{(s)} \propto \frac{p(\theta^{(s)} \mid y)}{q(\theta^{(s)})}, \qquad E(g(\theta) \mid y) \approx \frac{\sum_s w^{(s)} g(\theta^{(s)})}{\sum_s w^{(s)}}$$

⚠ **WARUNEK KONIECZNY**

q(θ) musi miec **ciezsze ogony** niz p(θ|y). Jezeli nie → wagi niestabilne → wyniki bezuzyteczne. Odpowiedz (c) pytania 5 egzaminu = **FALSZ**.

W8 — Probnik Gibbsa

probnik Gibbsa | Gibbs | rozklady warunkowe | lancuch Markowa | bridge sampling

$$\theta_i^{(s)} \sim p\left(\theta_i \mid \theta_{-i}^{(s-1)}, y\right) \quad i = 1, \ldots, K$$

Krok dla regresji (krok 1 → krok 2 → powtorz):

$$\beta \mid h, y \sim N(\mu^*, \Sigma^*), \quad \Sigma^* = (hX^TX + U^{-1})^{-1}, \quad \mu^* = \Sigma^*(hX^Ty + U^{-1}\bar{\beta}_0)$$

$$h \mid \beta, y \sim \Gamma(\bar{v}/2,\ \bar{v}\bar{s}^2/2)$$

W9 — Algorytm Metropolisa-Hastingsa (MH)

Metropolis-Hastings | MH | stopa akceptacji | diagnostyka MCMC | CODA | Geweke | Heidelberg-Welch | Gelman-Rubin | R-hat | burn-in | trace plot

[ERR: \alpha(\theta^*,\theta^{(s-1)}) = \mi]

Kryterium skutecznosci: stopa akceptacji ∈ [0.25; 0.40].

Test CODA	Idea	Funkcja R
Geweke	Porownuje srednie 10% poczatku i 50% konca. Zbiezny → ~N(0,1)	`geweke.diag()`
Heidelberg-Welch	Test stacjonarnosci; iteracyjnie odcina burn-in	`heidel.diag()`
Gelman-Rubin	$\hat{R} < 1.05$ → zbieznosc (wiele lancuchow)	`gelman.diag()`
Trace plot	Zbiezny = "klebek welny"	`traceplot()`

W10 — Monte Carlo Hamiltona (HMC)

HMC NUTS Stan gradient energia potencjalna MH vs HMC

$$U(\theta) = -\log p(\theta \mid y) \quad \text{(energia potencjalna)}$$

	MH Random Walk	HMC (NUTS/Stan)
Eksploracja	Bladzenie losowe	Gradient $\nabla \log p$ — kierunkowe
Kalibracja	Wymaga σ_{prop}	Automatyczna (NUTS)
Autokorelacja	Wysoka	Niska
Wymagania	$p(\theta\|y)$ w punkcie	Gradient $\nabla \log p(\theta\|y)$

W11 — Predykcja przy nieznanych regresorach

predykcja numeryczna nieznane regresory imputacja nowcasting

$$p(y_\tau \mid y) = \iiint p(y_\tau \mid \beta, h, x_\tau) \cdot p(x_\tau) \cdot p(\beta, h \mid y)\, d\beta\, dh\, dx_\tau$$

Numerycznie: losuj $(\beta^{(s)}, h^{(s)})$, losuj $x_\tau^{(s)}$, oblicz $y_\tau^{(s)} = x_\tau^{(s)}\beta^{(s)} + \varepsilon^{(s)}$. Histogram = rozklad predykcyjny.

W12 — BMA

BMA Bayesowskie usrednianie modeli prawdopodobienstwo inkluzji BMS 2^K modeli

$$P(M_j \mid y) = \frac{P(y \mid M_j) \cdot P(M_j)}{\sum_l P(y \mid M_l) \cdot P(M_l)}$$

$$E(y_\tau \mid y) = \sum_j E(y_\tau \mid y, M_j) \cdot P(M_j \mid y)$$

[ERR: $P(\beta_k\neq 0\mid y) = \sum_{j:\,x_]

Egzamin przykladowy

22.12.2016 r. — Pelne tresci + wykresy + rozwiazania

dr Andrzej Toroj · przy kazdym zadaniu: lokalizacja w wykladach

Zadanie 1 — pytanie otwarte

Model z a priori U(0,1) — gestosc a posteriori i granice calkowania

a priori U(0,1) | granice calkowania | KLUCZOWE | wskaznik indykatorowy | E(sigma|y) | gestosc a posteriori

W1 (twierdzenie Bayesa, gestosc a posteriori) · **W3** (gestosc probkowa przy normalnym skladniku losowym)

Rozkazujemy model regresji z jedna zmienna, nieznaną wariancja i **bez stalej**. Wspolczynnik β oraz **odchylenie std σ** maja a priori rozklad jednostajny na (0,1). Skladniki losowe ~ N(0,σ²) i.i.d.

(a) Zapisz model. **(b)** Wyznacz laczna gestosc a posteriori (mianownik = stala a). **(c)** Zapisz calke na E(σ|y) — uwaga na granice.

✓ **Rozwiazanie**

(a) Model i a priori:

$$y_i = \beta x_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2), \quad \beta \sim U(0,1),\ \sigma \sim U(0,1)$$

(b) Laczna gestosc a posteriori:

$$p(\beta, \sigma \mid y) = \frac{1}{a} \cdot (2\pi)^{-n/2} \cdot \sigma^{-n} \cdot \exp\left[-\frac{\sum (y_i - \beta x_i)^2}{2\sigma^2}\right] \cdot \mathbf{1}_{[0,1]}(\beta) \cdot \mathbf{1}_{[0,1]}(\sigma)$$

(c) E(sigma|y) — GRANICE [0,1]x[0,1], NIE (-inf,+inf)x(0,+inf)!

$$E(\sigma \mid y) = \int_0^1 \int_0^1 \sigma \cdot p(\beta, \sigma \mid y)\, d\beta\, d\sigma$$

⚠ *Kluczowy blad: granice (0,+inf) dla sigma ignoruja fakt, ze U(0,1) zeruje gestosc dla sigma>1.*

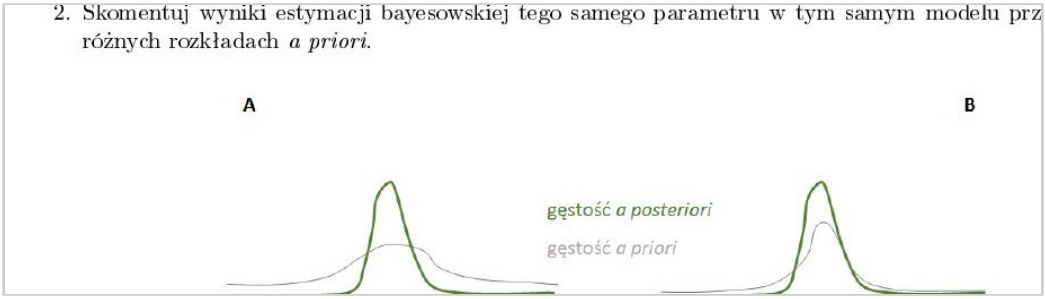
Zadanie 2 — pytanie otwarte

Komentarz do wykresow A i B — dwa rozne rozklady a priori

wykresy a priori a posteriori | waga danych vs a priori | beta_bar srednia wazona | W1 wplyw wariancji

W1 (wplyw wariancji a priori na a posteriori) · **W3** (beta_bar = srednia wazona beta_0 i OLS)

Skomentuj wyniki estymacji przy dwoch roznych a priori (ten sam model, te same dane).



Zielona = a posteriori, szara = a priori. Czarna linia ≈ OLS.

✓ **Rozwiazanie**

Wykres A (szerokie a priori): dane dominuja → a posteriori silnie przesuwa sie ku OLS.

Wykres B (waskie a priori): a priori dominuje → a posteriori pozostaje blisko a priori.

$$E(\beta \mid y) = w \cdot \bar{\beta}_0 + (1 - w) \cdot \hat{\beta}_{\text{OLS}}, \quad w = \frac{u^{-1}}{u^{-1} + S_X}$$

Wzrost wariancji a priori (u rosnie) → w maleje → E(beta|y) blizej OLS. Var a posteriori zawsze ≤ Var a priori.

Zadanie 3 — pytanie otwarte

Wariancja a posteriori beta w modelu N-G — wzor i interpretacja

Var(beta|y) · stopnie swobody · S_X · rozklad t · v_bar s_bar u_bar

W3 (parametry a posteriori N-G, rozklad t) · **W4** (wersja macierzowa)

Od czego i jak zalezy Var(β|y)?

✓ **Rozwiazanie**

$$\beta \mid y \sim t(\bar{\beta},\ \bar{s}^2\bar{u},\ \bar{v}) \quad \Rightarrow \quad \text{Var}(\beta \mid y) = \frac{\bar{v} \cdot \bar{s}^2 \cdot \bar{u}}{\bar{v} - 2}$$

Maleje gdy: N↑ → $barv = v + N$ rosnie; S_X↑ → $baru = (u^{-1} + S_X)^{-1}$ maleje; u↓ (silniejsze a priori) → $baru$ maleje; $bars^2$ maleje (lepsze dopasowanie).

Zadanie 4 — pytanie otwarte

HPDI 95% dla alpha_1 z danego rozkladu a posteriori N-G

HPDI obliczenie · rozklad t · qt.scaled · metRology · s_bar U_bar

W4 (HPDI, qt.scaled, rozklad t brzegowy) — wzory w sekcji HPDI

A posteriori: $[\alpha_0, \alpha_1]^T \sim NG(\bar{\alpha} = [0, 1]^T,\ \bar{U} = \text{diag}(0.2, 0.1),\ \bar{s}^{-2} = 0.3,\ \bar{v} = 10)$. Wyznacz HPDI 95% dla α_1.

✓ **Rozwiazanie**

$$\alpha_1 \mid y \sim t\left(1,\ \frac{1}{0.3}\cdot 0.1 = \frac{1}{3},\ 10\right), \quad \mathrm{SD} = \sqrt{1/3} \approx 0.5774$$

$$\mathrm{HPDI}_{95\%}(\alpha_1) \approx (1 - 2.228 \cdot 0.5774\ ;\ 1 + 2.228 \cdot 0.5774) \approx (-0.29\ ;\ 2.29)$$

```
library(metRology) qt.scaled(c(0.025, 0.975), df=10, mean=1, sd=sqrt(1/3)) # [1]
-0.287 2.287
```

— Pytania testowe 5–9 —

Pytanie 5 — IS, macierz Theta 10000x5

Importance Sampling | macierz theta | E(theta2|y) | ciezkie ogony q(theta)

W7 (IS — wymagania q(theta), estymacja E(g(theta)|y) usrednianiem kolumny macierzy)

(a) Wyznaczenie rozkladu predykcyjnego nie wymaga zal. o normalnosci.

(b) ✓ Aby uzyskac E(θ_2|y) nalezy usrednic druga kolumne macierzy Θ.

(c) Dowolna q przyniesie satysfakcjonujace wyniki IS.

(d) Zadna z powyzszych.

✓ (b) — dlaczego?

$$E(\theta_2 \mid y) \approx \frac{1}{S}\sum_{s=1}^{S} \Theta_{s,2} \quad \text{(prawo wielkich liczb)}$$

(a) FALSZ — potrzebujemy rozkladu e (np. N) aby wylosowac y_tau. **(c) FALSZ** — q musi miec ciezsze ogony niz p(theta|y), inaczej wagi → niestabilnosc.

Pytanie 6 — skrajnie nieinformacyjne a priori → E(beta|y) blizkie...

nieinformacyjne a priori | OLS limit | u^{-1}->0

W4 (N-G wariant nieinformacyjny, dowod beta_bar → OLS)

(b) ✓ OLS

✓ (b) — dlaczego?

[ERR: \bar\beta = \dfrac{\hat\beta S_X + \bar]

Pytanie 7 — E(beta|y)=10, E(beta)=8, beta_hat=6: czy mozliwe dla N-G?

N-G ograniczenia | srednia wazona | beta_bar in [min,max]

W3 (beta_bar = srednia wazona; zakres [min(beta_0, OLS), max(beta_0, OLS)])

(c) ✓ Niemozliwe dla N-G; mozliwe dla innych a priori.

✓ **(c) — dlaczego?**

$$\bar{\beta} = w \cdot \bar{\beta}_0 + (1-w) \cdot \hat{\beta} \Rightarrow \bar{\beta} \in [6, 8]. \quad \text{Wartosc 10 poza zakresem.}$$

Dla niesprzezonych a priori a posteriori moze miec tryb poza tym przedzialem → mozliwe.

Pytanie 8 — BF=1.02

BF interpretacja | barely worth mentioning | skala Jeffreysa | BF vs istotnosc parametru

> **W5** (BF, skala Jeffreysa, rozroznienie: BF porownuje modele nie parametry)

(d) ✓ Model ze x10 nie jest ani lepszy, ani gorszy.

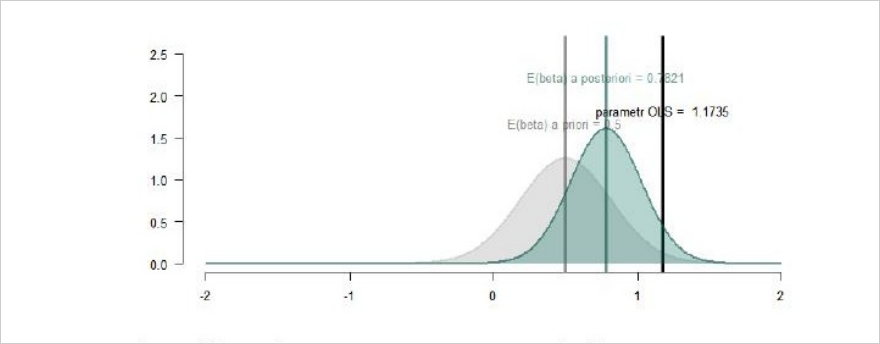
✓ **(d) — dlaczego?**

BF=1.02 ≈ 1 → "barely worth mentioning". Dane praktycznie nie zmienily preferencji. Uwaga: BF porownuje *modele*, nie mowi o istotnosci parametru. Do oceny istotnosci: HPDI lub P(beta_i!=0|y).

Pytanie 9 — wzrost wariancji a priori → E(beta|y) rosnie/maleje?

wzrost wariancji a priori | E(beta|y) rosnie | waga a priori maleje | W3 srednia wazona

> **W3** (beta_bar = srednia wazona, wplyw u) · **W4** (nieinformacyjne a priori → OLS)



Szary≈0.5 (a priori), zielony≈0.78 (a posteriori), czarna linia≈1.17 (OLS)

(a) ✓ Wzrost E(β|y).

✓ **(a) — dlaczego?**

E(beta|y)≈0.78 miedzy a priori (0.5) a OLS (1.17). Wzrost wariancji a priori → waga a priori maleje → E(beta|y) → OLS (1.17) → **rosnie**.

(b) FALSZ — Var(beta|y) tez rosnie (slabsze a priori). **(c) FALSZ** — wariancja predykcyjna $bar_s^2(1 + x_t aubar_U x_t au^T)$ tez rosnie gdy bar_U rosnie.

Egzamin probny 1

Parametry a posteriori · obliczenia · BF · MCMC

P1 — Z1

Wzory na parametry a posteriori N-G i interpretacja wagi beta_0

parametry a posteriori | waga beta_0 | U^{-1}/(U^{-1}+XTX) | srednia wazona

W4 (wzory macierzowe a posteriori, rola U^-1 i XTX w wadze beta_0 vs danych)

✓

$$\bar{\beta} = (U^{-1} + X^T X)^{-1}(U^{-1}\bar{\beta}_0 + X^T y), \quad \bar{U} = (U^{-1} + X^T X)^{-1}, \quad \bar{v} = v + N$$

Waga bar_beta_0: proporcjonalna do U^{-1}. Im mniejsze U (silniejsze a priori) → wieksza rola bar_beta_0. Im wiecej danych (X^TX rosnie) → mniejsza rola bar_beta_0.

P1 — Z2

Obliczenie P(beta_2 < -2 | y)

P(beta | dystrybuanta t | standaryzacja | rozklad t brzegowy

W3/W4 (rozklad brzegowy beta ~ t, standaryzacja i dystrybuanta)

A posteriori: $\beta = [2, -1.5]^T \sim NG(\bar{\beta}, \bar{U} = \text{diag}(0.4, 0.2), \bar{s}^{-2} = 5, \bar{v} = 30)$. Oblicz $P(\beta_2 < -2 \mid y)$.

✓

$$\beta_2 \mid y \sim t(-1.5,\ 0.04,\ 30), \quad \text{SD} = 0.2$$

$$P(\beta_2 < -2 \mid y) = P\left(t_{30} < \frac{-2-(-1.5)}{0.2}\right) = P(t_{30} < -2.5) \approx 0.009$$

P1 — Z3

Obliczenie HPDI 90% dla beta_2

HPDI obliczenie | 90% | qt.scaled | istotnosc beta

W4 (HPDI, qt.scaled, poziom 90% czyli alpha=0.10 → kwantyle 5% i 95%)

A posteriori $NG(\bar{\beta} = [1.2, -0.8]^T, \bar{U} = \text{diag}(0.5, 0.3), \bar{s}^{-2} = 4, \bar{v} = 20)$. Kwantyl $t_{0.05,\,20} \approx 1.725$.

✓

$$\beta_2 \mid y \sim t(-0.8,\ 0.075,\ 20), \quad \text{SD} \approx 0.274$$

$$\text{HPDI}_{90\%} \approx (-0.8 - 1.725 \cdot 0.274\ ;\ -0.8 + 1.725 \cdot 0.274) \approx (-1.27\ ;\ -0.33)$$

Zero nie nalezy → beta_2 **istotnie ujemna** na poziomie 10%.

P1 — Z4

Obliczenie BF, PO i P(M1|y)

BF obliczenie | PO obliczenie | P(M|y) | substantial evidence

W5 (BF = P(y|M1)/P(y|M2), PO = BF * P(M1)/P(M2), P(M1|y) ze wzoru)

$P(y|M_1) = 4 \cdot 10^{-8},\ P(y|M_2) = 8 \cdot 10^{-9},\ P(M_1) = 0.3,\ P(M_2) = 0.7\,.$

✓

$$\text{BF}(1,2) = \frac{4 \cdot 10^{-8}}{8 \cdot 10^{-9}} = 5 \quad \text{(substantial evidence za } M_1\text{)}$$

$$\text{PO}(1,2) = 5 \cdot \frac{0.3}{0.7} \approx 2.14, \qquad P(M_1 \mid y) = \frac{2.14}{3.14} \approx 0.68$$

Dane odwrocily preferencje: P(M1)=0.3 → P(M1|y)=0.68.

P1–P5: Gibbs vs IS

W7 (IS), **W8** (Gibbs — rozklady warunkowe vs q(theta))

(c) ✓ Gibbs wymaga rozkladow warunkowych p(theta_i|theta_minus_i,y); IS nie.

✓ **(c)**

Gibbs: losuje kolejno z K rozkladow warunkowych. IS: losuje z dowolnej q i koryguje wagami. Gibbs tworzy lancuch Markowa (probki zalezne), IS daje (wazone) niezalezne probki. Odp. (a) — odwrocona.

P1–P6 do P1–P9

P6: **W3** (u_bar=(u^{-1}+SX)^{-1} maleje z N) | P7: **W6** (wzor rozkladu predykcyjnego) | P8: **W9** (burn-in) | P9: **W12** (BMA usrednia, nie wybiera)

P6 (b) ✓ — Spada u_bar (Var(beta|y) maleje), rosnie v_bar.

P7 (c) ✓ — $t(x_\tau \bar{\beta},\ \bar{s}^2(1 + x_\tau \bar{U} x_\tau^T),\ \bar{v})$.

P8 (a) ✓ — Burn-in usuwa obserwacje zalezne od wartosci startowej.

P9 (b) ✓ FALSZ — BMA *usrednia* prognozy po 2^K modelach, nie wskazuje jednego.

Egzamin probny 2

Pytania koncepcyjne · Gibbs · BF vs P(beta>0|y)

P2 — Z1

Wzrost wariancji a priori przesuwa E(beta|y) ku E(beta)_prior?

waga a priori maleje | u^{-1} maleje | E(beta|y) -> OLS

W3 (beta_bar = srednia wazona, waga w = u^{-1}/(u^{-1}+SX))

✓ **FALSZ — odwrotnie!**

$w = \frac{u^{-1}}{u^{-1} + S_X}$ wzrost wariancji a priori (u rosnie) → u^{-1} maleje → w maleje

E(beta|y) zbliza sie do OLS, nie do a priori. Intuicja: "slabsze przekonania a priori → bardziej ufam danym".

P2 — Z2

Krok Gibbsa dla modelu ze stala

krok Gibbsa | rozklady warunkowe | beta|h,y | h|beta,y

W8 (probnik Gibbsa — kroki dla modelu y_i=beta+e_i)

Model: $y_i = \beta + \varepsilon_i$, $\varepsilon \sim N(0, h^{-1})$, a priori $\beta \sim N(\mu_0, \tau_0^2)$, $h \sim \Gamma(a, b)$.

✓

$$\beta \mid h, y \sim N(\mu^*, \sigma^{2*}), \quad \sigma^{2*} = (hN + \tau_0^{-2})^{-1}, \quad \mu^* = \sigma^{2*}(hN\bar{y} + \mu_0\tau_0^{-2})$$

$$h \mid \beta, y \sim \Gamma\left(a + \frac{N}{2},\ b + \frac{\sum(y_i - \beta)^2}{2}\right)$$

P2 — Z3

P(beta1>0|y)=0.95 vs P(beta2>0|y)=0.80 — ktora zmienna istotniejsza?

BF restrykcje | zmiana szans | P(beta>0|y) | P(beta>0) prior

W5 (PO = BF * P(H)/P(H^c), BF = zmiana szans na nierownosc)

$P(\beta_1 > 0)_{\text{prior}} = 0.5$, $P(\beta_2 > 0)_{\text{prior}} = 0.95$.

✓ **beta_1 bardziej istotna bayesowsko**

$$\mathrm{BF}(\beta_1 > 0) = \frac{0.95/0.05}{0.5/0.5} = 19 \quad \text{(strong evidence)}$$

$$\mathrm{BF}(\beta_2 > 0) = \frac{0.80/0.20}{0.95/0.05} \approx 0.21 \quad \text{(dane OSLABIŁY przekonanie!)}$$

BF dla beta_2 <1 — dane przemawiaja PRZECIW hipotezie beta_2>0. Mimo P(beta_2>0|y)=0.80 wydaje sie duze, a priori bylo 0.95.

P2 — Z4

Przy N->inf wyniki bayesowskie = OLS

zbieznosc do OLS | N->infinity | SX->infinity

W4 (nieinformacyjne a priori: SX dominuje U^{-1} → beta_bar → OLS)

✓

$$N \to \infty \Rightarrow S_X \to \infty \Rightarrow \bar{u} = (u^{-1} + S_X)^{-1} \approx S_X^{-1} \to 0$$

$$\bar{\beta} = \frac{\hat{\beta} S_X + \bar{\beta}_0 u^{-1}}{S_X + u^{-1}} \approx \hat{\beta}_{\mathrm{OLS}}$$

A priori "topi sie" w ogromie danych. Analogicznie bar_U → (X^TX)^{-1}.

P2–P5 do P2–P9

P5: **W4** (HPDI bezposrednia interpretacja vs CI) | P6: **W5** (BF<1 → za M2) | P7: **W9** (R-hat<1.05) | P8: **W5** (restrykcja vs pomiar P) | P9: **W8** (bridge sampling dla t-skladnika)

P5 (b) ✓ HPDI: P(β∈HPDI|dane)=0.95 — bezposrednia interpretacja probabilistyczna.

P6 (c) ✓ BF=0.3 → dane przemawiaja za M2. BF(M2,M1)=3.33 (positive).

P7 (b) ✓ R-hat=1.8 >> 1.05 → lancuch NIE zbiegł.

P8 (b) ✓ Wbudowanie w a priori narzuca restrykcje; P(beta>0|y) tylko mierzy prawdopodobienstwo.

P9 (c) ✓ P(y|M) z t-skladnikiem wymaga bridge sampling (pakiet bridgesampling w R).

Egzamin probny 3

Obliczeniowy · HPDI · MH vs HMC · predykcja numeryczna

P3 — Z1

Oblicz beta_bar, u_bar, v_bar i HPDI 95%

obliczenia N-G | beta_bar | u_bar | v_bar | HPDI obliczenie

W3 (wzory beta_bar, u_bar, v_bar) · **W4** (HPDI — qt.scaled z metRology)

N=50, $\sum x^2 = 200$, $\sum xy = 120$. A priori: $\bar{\beta}_0 = 0.5$, u=0.02, $s^2 = 1$, v=50. Kwantyl $t_{0.025,\,100} \approx -1.984$.

✓

$$\hat{\beta} = \frac{120}{200} = 0.6, \quad \bar{u} = (50 + 200)^{-1} = \frac{1}{250} = 0.004, \quad \bar{v} = 100$$

$$\bar{\beta} = \frac{0.6 \cdot 200 + 0.5 \cdot 50}{250} = \frac{145}{250} = 0.58, \quad \text{SD} = \sqrt{1 \cdot 0.004} \approx 0.063$$

$$\text{HPDI}_{95\%} \approx (0.58 - 1.984 \cdot 0.063\ ;\ 0.58 + 1.984 \cdot 0.063) \approx (0.455\ ;\ 0.705)$$

Zero nie nalezy → beta istotnie dodatnia na 5%.

P3 — Z2

Pelny algorytm Gibbsa dla modelu ze stala

algorytm Gibbsa | inicjalizacja | burn-in | thinning | lancuch Markowa

W8 (probnik Gibbsa — algorytm krok po kroku, wzory rozkladow warunkowych)

✓

Inicjalizacja: wybierz $beta^{(0)}, h^{(0)}$. Dla s=1,...,S:

Krok 1: $\beta^{(s)} \sim N(\mu^*, \sigma^{2*}), \quad \sigma^{2*} = (h^{(s-1)}N + \tau_0^{-2})^{-1}, \quad \mu^* = \sigma^{2*}(h^{(s-1)}N\bar{y} + \mu_0\tau_0^{-2})$

$$\text{Krok 2: } h^{(s)} \sim \Gamma\left(a + \frac{N}{2},\ b + \frac{\sum (y_i - \beta^{(s)})^2}{2}\right)$$

Odrzuc burn-in. Stosuj thinning przy wysokiej autokorelacji.

P3 — Z3

Numeryczny rozklad predykcyjny — procedura

predykcja numeryczna | MCMC predykcja | dwa zrodla niepewnosci

W11 (predykcja numeryczna — procedura, niepewnosc parametrow + skladnika losowego)

✓

Dla s=1,...,S: (1) Pobierz $(beta^{(s)}, h^{(s)})$ z lancucha MCMC (po burn-in). (2) Wylosuj $eps^{(s)}$ $N(0, (h^{(s)})^{-1})$. (3) Oblicz $y_tau^{(s)} = x_tau * beta^{(s)} + eps^{(s)}$.

Histogram {y_tau^(s)} ≈ p(y_tau|y). Dwa zrodla niepewnosci: (1) beta i h — krok 1, (2) skladnik losowy — krok 2.

P3 — Z4

Porownanie MH i HMC

MH vs HMC | Random Walk | NUTS | Stan | efektywnosc MCMC | autokorelacja

W9 (MH — stopa akceptacji, wady) · **W10** (HMC — gradient, NUTS, Stan)

✓

	MH Random Walk	HMC (NUTS/Stan)
Eksploracja	Bladzenie losowe	Gradient $nablalogp$ — kierunkowe
Kalibracja	Wymaga $sigma_prop$ [0.25,0.40]	Automatyczna (NUTS)
Autokorelacja	Wysoka	Niska
Wymagania	$p(theta\|y)$ w punkcie	Gradient $nablalogp(theta\|y)$

P3–P5 do P3–P9

P5: **W9** (stopa 0.05<<0.25 → za duze kroki) | P6: **W5** (BF=PO przy rownych a priori) | P7: **W3** (h~Gamma → sigma^2~Inv-chi^2) | P8: **W7** (nosnik q, ciezkie ogony) | P9: **W4** (nieinformacyjne → bar_U → (XTX)^{-1})

P5 (c) ✓ Zmniejszyc sigma_prop — stopa 0.05 << 0.25, kroki za duze, kandydaci odrzucani.

P6 (b) ✓ BF=PO=0.7/0.3≈2.33 przy rownych a priori.

P7 (c) ✓ [ERR: $\sigma^2\mid y\sim\mathrm{{Inv}}\text{[].

P8 (c) ✓ Nosnik q musi zawierac nosnik p(theta|y); q — ciezsze ogony.

P9 (b) ✓ $\bar{s}^2 \cdot \bar{U}_{ii} \cdot \bar{\nu}/(\bar{\nu}-2)$ ≈ odpowiednik MSE*(XTX)^{-1}_{ii} z OLS.

Koniec notatek · Ekonometria Bayesowska · dr Andrzej Toroj · SGH Warszawa